

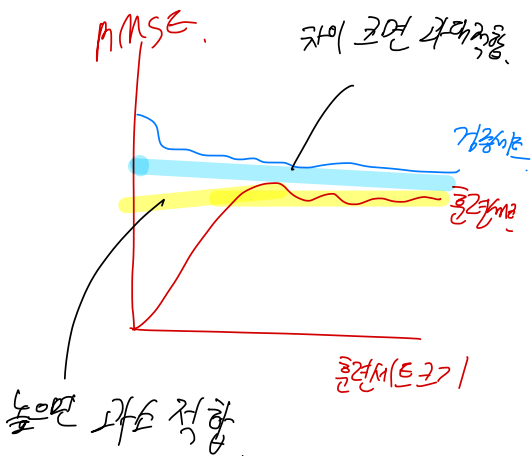
학습 곡선

비선형 데이터.


과대적합 & 과소적합 확인하는 방법?

차수 (복잡도) 결정하는 방법?

⇒ 학습 곡선



(ideal)



차수는 입력해야 함.

(but 차수가 별로 없으면...)

특성 n

차원 d

$$\rightarrow \frac{(n+d)!}{n! \cdot d!}$$

새로운 특성.

Vector norm $\|V\|_{p=1,2,\infty,\dots}$


$$p=1, \quad \|V\|_1 = |V_1| + |V_2| + \dots + |V_n|$$

$$p=2, \quad \|V\|_2 = \sqrt{|V_1|^2 + |V_2|^2 + \dots + |V_n|^2}$$


$$p=\infty, \quad \|V\|_\infty = \max |V_i|$$

$\|V\|_p = 1$ in \mathbb{R}^2


$p = \frac{1}{2}$




$p=1$



$p=2$



$p=\infty$




"거리의 정의가 바뀌면 level set ($\|V\|=k$)의 모양이 바뀐다!"

그래프를 바라보는 두 가지 관점.

i) Graph of function.

ii) Graph of level set.



f : function $\Rightarrow \nabla f$: the direction of which f is increasing the fastest.
 F : level set $\Rightarrow \nabla F$: normal vector of tangent plane.

규제

- 라지 회귀

$$J(\theta) = \text{MSE} + \frac{1}{2} \lambda \underbrace{\sum_{i=1}^n \theta_i^2}_{l_2\text{-norm}}$$

특징

그래디언트 구하기 쉬움


- 라쏘 회귀

$$J(\theta) = \text{MSE} + \lambda \underbrace{\sum_{i=1}^n |\theta_i|}_{l_1\text{-norm}}$$

$\theta_i = 0$ (중요하지 않은 특성들)


걸러낼 수 있음

$l_1\text{-norm}$



Lasso가 $\theta_i = 0$ 많은 이유.
(가까운 쪽으로 먼저 떨어짐)

$l_2\text{-norm}$



Note.

- 규제 전 데이터 전처리 해야함.
- 규제 항목은 훈련하는 동안에만 사용

$$\begin{pmatrix} \lambda \geq 0 \\ \lambda \geq |\theta_i| \end{pmatrix}$$

훈련에 사용하는 비용함수 & 테스트에 사용하는 비용함수. 다를 수 있음.
↓
미분 가능해야 함.

→
목적에 따라 다를 수 있음.


ex) 코시스트릭 → 테스트에서는 정밀도/재현율로 평가.

로지스틱 회귀

∴ 회귀 알고리즘을 분류에 사용

$$X \longrightarrow \sigma(\theta^T X) = \hat{p} \quad \left(\begin{array}{l} \hat{p}: 50\% \uparrow \longrightarrow 0 \\ \quad \quad 50\% \downarrow \longrightarrow X \end{array} \right)$$

sigmoid function $\sigma(t) = \frac{1}{1+e^{-t}}$




확률적인 해석 가능.

$$\text{but } \sum_{i=1}^n (y - \sigma(\theta^T X))^2$$

MSE를 Loss function으로 쓰기에 계산량 너무 많음.

⇒ 로지스틱에 맞는 Loss Function "cross-entropy" 정의.

$$X \longrightarrow \sigma(\Theta^T X)$$



x_1, x_2, \dots, x_n : 독립시행 \Rightarrow We want to maximize $\prod_{k=1}^n P(x_k)$.

$$\text{maximize } \prod_{k=1}^n P(x_k)$$

$$\Leftrightarrow \text{minimize } -\prod_{k=1}^n P(x_k)$$

$$\Leftrightarrow \text{minimize } \log\left(-\prod_{k=1}^n P(x_k)\right)$$

log 함수의 성질

• Monotone increase.

$$(x_1 < x_2 \longrightarrow \log x_1 < \log x_2)$$

$$\cdot \log(1) = 0$$

(확률이 1이면 오차 0)

$$\cdot \log(x_1 x_2) = \log x_1 + \log x_2$$

(증거한 값의 변화를 완화시켜줌)

$$(x \longrightarrow +)$$

$$\Rightarrow \text{Loss} = -\log \left(\prod_{k=1}^n P(x_k) \right)$$

$$= -\sum_{k=1}^n \log P(x_k)$$

$$\left(\text{MSE: } \sum_{k=1}^n (y_k - \sigma(\theta^T x_k))^2 \right)$$

in book.

$$J(\theta) = -\frac{1}{n} \sum_{k=1}^n \left[y^{(k)} \log(p^{(k)}) + (1-y^{(k)}) \log(1-p^{(k)}) \right]$$

\Rightarrow l_2 -norm 을 이용한 Loss Function 이 아니기 때문에 정규화정식 쓸 수 없음.

but gradient 생각보다 간단. $\begin{pmatrix} \sigma'(t) = \sigma(t)(1-\sigma(t)) \\ e^x \text{ 왜?} \end{pmatrix}$

- 로지스틱 회귀도 규제 가능.

- 결정 경계는 선형. ($\theta^T X = 0$).



비선형 레이어럴 경우,

(kNN ,
SUM
NN

소프트맥스 회귀.

∴ 다항 분류.

ex) A, B, C 분류.



다항 분류에서는 Sigmoid 사용 X.

A인 항목

$$(\theta^{(1)})^T X$$

20

B인 항목

$$(\theta^{(2)})^T X$$

10

C인 항목

$$(\theta^{(3)})^T X$$

10

$$\Rightarrow \frac{10}{20 + 10 + 10} \text{ 항목으로 } B,$$

차이를 더 복잡시키는 방법?

$$\theta^T x \rightarrow e^{\theta^T x}$$

$$|5 - 3| = 2$$

↓

$$|2^5 - 2^3| = 24$$

$$e^{(\theta^{(1)})^T X} = e^{s_1}$$

A의 값

$$\rightarrow \frac{e^{s_1}}{e^{s_1} + e^{s_2} + e^{s_3}}$$

$$e^{(\theta^{(2)})^T X} = e^{s_2}$$

B의 값

$$\rightarrow \frac{e^{s_2}}{e^{s_1} + e^{s_2} + e^{s_3}}$$

$$e^{(\theta^{(3)})^T X} = e^{s_3}$$


C의 값

$$\rightarrow \frac{e^{s_3}}{e^{s_1} + e^{s_2} + e^{s_3}}$$

$\max P_i$

$$\hat{P}_k = \frac{e^{s_k(x)}}{\sum_{j=1}^K e^{s_j(x)}}$$

Loss function?



\Rightarrow Cross-entropy At-G.

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left(\sum_{k=1}^K y_k^{(i)} \log(\hat{p}_k^{(i)}) \right)$$

y 가 k_0 클래스에 속한다면

$$y_1^{(i)} \cancel{\log(\hat{p}_1^{(i)})} + y_2^{(i)} \cancel{\log(\hat{p}_2^{(i)})} + \dots + \boxed{y_{k_0}^{(i)} \log(\hat{p}_{k_0}^{(i)})} + \dots + y_K^{(i)} \cancel{\log(\hat{p}_K^{(i)})}$$

$$\Rightarrow -\frac{1}{m} \sum_{i=1}^m \log(\hat{p}_{k_0}^{(i)})$$

Cross-entropy 의 결정 경계?

$$\frac{e^{s_1(x)}}{\sum_{j=1}^k e^{s_j(x)}} = \frac{e^{s_2(x)}}{\sum_{j=1}^k e^{s_j(x)}}$$

$$\Rightarrow e^{s_1(x)} = e^{s_2(x)}$$

$$\Rightarrow s_1(x) = s_2(x)$$

$$\Rightarrow \theta_0^{(1)} + \theta_1^{(1)} x_1 + \dots + \theta_n^{(1)} x_n = \theta_0^{(2)} + \theta_1^{(2)} x_1 + \dots + \theta_n^{(2)} x_n$$

$$\Rightarrow (\theta_0^{(1)} - \theta_0^{(2)}) + (\theta_1^{(1)} - \theta_1^{(2)}) x_1 + \dots + (\theta_n^{(1)} - \theta_n^{(2)}) x_n = 0$$

softmax 의 결정 경계는 선형!

